

Predição de Risco de Morte SRAG - HistGradientBoostingClassifier

Alunas: Fernanda Lima de Souza; Anna Bheatriz Martins dos Santos; Esther Victória Santos Alves

Resumo

Este trabalho apresenta o desenvolvimento de um modelo de *machine learning* para prever o risco de morte em pacientes com Síndrome Respiratória Aguda Grave (SRAG), usando dados da competição "IA UFMT 2025" promovida pelo professor Dr. Rafael Teixeira de Sousa na plataforma Kaggle. O algoritmo *HistGradientBoostingClassifier* foi aplicado em um pipeline que incluiu pré-processamento, engenharia de *features* para criar variáveis relevantes (como total de comorbidades e risco com a idade) e a técnica de *oversampling* para tratar o desbalanceamento entre os resultados de cura e óbito. O modelo foi avaliado com validação cruzada estratificada, alcançando um desempenho consistente e sólido, com métricas como Área sob a Curva ROC (AUC) média de **0,8073** e um F1-Score de **0,7385**. Os resultados demonstram a capacidade do modelo em discriminar pacientes de alto risco, reforçando a possibilidade de usar inteligência artificial como ferramenta de apoio à decisão clínica e à gestão de recursos de saúde.

Palavras-chave: *Predição de risco de morte por SRAG; SRAG; Machine Learning; HistGradientBoostingClassifier; Modelos preditivos; Classificação de risco; Inteligência Artificial aplicada à saúde; Análise de dados médicos.*

1. Introdução

A Síndrome Respiratória Aguda Grave (SRAG) é uma condição clínica descrita por complicações respiratórias graves, frequentemente ligada a altas taxas de mortalidade, especialmente em casos de infecção por COVID-19. Desde o início da pandemia, o Brasil acumulou um grande volume de dados relacionados a pacientes hospitalizados, o que gerou uma base expressiva para análises que podem auxiliar na identificação precoce de casos críticos e no direcionamento de recursos de saúde.

A predição do risco de morte em pacientes com SRAG é um desafio de grande relevância para a saúde pública, já que envolve trabalhar com diversidade de tipos de dados, desbalanceamento de classes e a existência de ruído nas variáveis. Nesse contexto, o uso de técnicas de *Machine Learning* tem se mostrado uma alternativa propícia na construção de modelos preditivos capazes de ajudar na tomada de decisão médica de maneira rápida e eficaz.

Este trabalho foi desenvolvido na disciplina de Inteligência Artificial da Universidade Federal de Mato Grosso (UFMT) e teve como base a competição *IA UFMT 2025 - Predição de risco de morte SRAG*, disponibilizada pelo professor Dr. Rafael Teixeira de Sousa, na plataforma Kaggle. O objetivo era aplicar algoritmos para prever e avaliar um modelo de classificação, sendo o escolhido o *HistGradientBoostingClassifier*, com foco em predição do risco de morte de pacientes diagnosticados com SRAG durante a Pandemia 2020 no Brasil.

2. Modelagem e Metodologia

O desenvolvimento da solução de predição do risco de morte por SRAG seguiu um pipeline, formado por seis etapas principais: coleta e organização dos dados, pré-processamento, balanceamento das classes, treinamento e validação do modelos, predição no conjunto de testes e execução do pipeline e geração das predições para submissão no Kaggle.

2.1. Análise Exploratória

Os dados utilizados foram fornecidos pela competição *IA UFMT 2025 - Predição de risco de morte SRAG*, disponibilizada na plataforma Kaggle. A base contém dois conjuntos distintos, tais eles:

Conjunto de treino: apresentava informações demográficas, clínicas e epidemiológicas de pacientes brasileiros diagnosticados com SRAG, incluindo a variável-alvo EVOLUCAO, em que 0 representa cura e 1 representa óbito.

Conjunto de teste: apresentava apenas as características dos pacientes, sem a variável-alvo, utilizado para avaliar o desempenho do modelo e gerar as submissões para a competição.

O primeiro passo fez-se uma análise exploratória para entender a estrutura dos dados. Verificado também a presença de valores nulos e os tipos de dados de cada variável, uma etapa fundamental para definir a estratégia de tratamento e modelagem.

2.2. Pré-processamento

O pré-processamento dos dados foi uma etapa mais crítica, uma vez que os dados originais continham variadas informações, valores faltantes e inconsistências que são comuns em bases epidemiológicas. As principais etapas foram:

Tratamento de variáveis categóricas: essa etapa foi responsável por preparar os dados brutos para treinamento do modelo. Variáveis como *sexo*, *raça*, *zona de residência* e *UF* foram transformadas em variáveis categóricas usando *Label Encoding*, enquanto sintomas e comorbidades foram convertidos em variáveis binárias. Alguns valores ausentes foram tratados com a mediana (para features numéricas) ou pela inclusão de uma categoria especial (“UNKNOWN”) em variáveis categóricas.

Também foi feita o **tratamento de variáveis binárias**: comorbidades como diabetes, obesidade, insuficiência renal, doenças hepáticas e imunodepressão e sintomas como febre, tosse, dispneia, fadiga, entre outros, foram convertidos em 1 (presença) ou 0 (ausência), levando em conta inclusive respostas ignoradas ou ausentes como 0, de modo a não introduzir viés.

Além das variáveis categóricas e binárias, algumas **variáveis contínuas** foram tratadas de forma específica em razão de sua relevância no meio clínico. A variável ***Idade (NU_IDADE_N)*** teve seus valores ausentes preenchidos pela mediana, mantendo a distribuição original da variável. Em seguida, foi criado um novo atributo derivado de idade, esse **idoso**, um indicador binário que assume valor 1 para pacientes com idade igual ou superior a 60 anos, a fim de identificar a população de maior risco.

Outra variável contínua tratada foi a **saturação de oxigênio (*SATURACAO*)**, a variável foi convertida para formato numérico, e valores inconsistentes foram tratados como ausentes. A partir dela, foi gerada outra variável binária ***saturacao_baixa***, que assume valor 1 para pacientes com saturação inferior a 95%, sendo um marcador clínico de gravidade. Valores ausentes foram imputados 98%, considerado valor de referência para saturação normal.

E por fim, a variável **Escolaridade (*CS_ESCOL_N*)** teve seus valores faltantes preenchidos com 0, além disso, criada a variável derivada ***baixa_educacao***, que adota valor 1 para pacientes com escolaridade inferior ou igual a 3 (até ensino fundamental incompleto).

Essa variável indicativa tem como objetivo entender a influência de fatores socioeconômicos no risco de morte.

Uma etapa importante no pré-processamento é a Engenharia de *Features*, onde novas variáveis foram criadas para ajudar o modelo com informações mais contextualizadas para com o perfil de risco de cada paciente. A partir dos dados, criou-se três novas *features*:

A primeira é o ***total_comorbidades***, esta variável representa o total de soma de todas as comorbidades de cada paciente, levando em conta doenças como diabetes, obesidade, insuficiência renal, doenças hepáticas e também imunodepressão. Essa nova *feature* é importante, pois ao invés de o modelo aprender que individualmente a diabetes é um risco, obesidade seria outro, essa variável já provém esse resumo. A hipótese é de que a **soma** dessas comorbidades aumenta significativamente o risco de um desfecho grave. Um paciente com 3 comorbidades tem um perfil de risco diferente de um tem apenas 1.

Quanto ao ***total_sintomas*** que é similar a ***total_comorbidades***, ele soma dos sintomas que o paciente apresentou. Nestes sintomas estão incluídos febre, tosse, dispneia, fadiga e entre outros. Ela indica a gravidade ou a dimensão da infecção.

E por fim, ***risco_idade_comorb*** serve para modelar a complexa interação entre idade e comorbidade. Ela calcula o produto da idade do paciente e seu número total de comorbidades. Essa *feature* foi criada para ajudar a entender que o risco associado a comorbidades é amplo em pacientes mais velhos, permitindo que o modelo obtenha essa relação não linear.

E concluindo a etapa de pré-processamento, houve uma limpeza final, removendo algumas colunas como *DT_NOTIFIC*, *DT_SIN_PRI*, *SEM_PRI*, como passo final, qualquer valor nulo restante foi preenchido com 0.

2.3. Balanceamento dos dados

A análise inicial do conjunto de dados revelou que variável-alvo *EVOLUCAO* apresentava grande desbalanceamento, com predominância no número de casos de pacientes que tiveram alta em relação aos óbitos. Esse desbalanceamento pode fazer com que o modelo foque mais em acertar os casos da classe mais comum, deixando de identificar corretamente os casos da classe menor, que são justamente os mais importantes para o problema.

Para lidar com esse problema e garantir que o modelo aprendesse os padrões das duas classes de maneira igualitária, foram aplicadas técnicas de reamostragem. Podendo ser ter a opção de escolha de três estratégias:

A primeira é *Undersample* remove aleatoriamente amostras da classe majoritária; Já a *Oversample* faz replicação de amostras da classe minoritária (óbitos) para aumentar sua representatividade; E por fim, *Misto* que combina a *Undersample* e *Oversample*, ajustando o tamanho das classes de forma proporcional.

Para o treinamento final, foi selecionado o método de ***Oversample***, que equilibrou as classes, garantindo que o modelo fosse treinado com uma representação igual de ambos os desfechos. O balanceamento das classes foi importante, pois a sub-representação de casos críticos (óbitos) pode levar o modelo a subestimar a mortalidade real, comprometendo a utilidade do modelo.

2.4. Treinamento e validação do modelo

Após o pré-processamento, a criação de novas features e o balanceamento dos dados, a etapa de treinamento foi iniciada na função *train_covid_model* que é responsável por treinar um modelo para prever a evolução de casos de *COVID-19* a partir de um conjunto de dados de treinamento fornecido. Ela segue um fluxo estruturado que envolve pré-processamento, balanceamento, treino com validação cruzada e finalmente o ajuste de um modelo final.

O primeiro passo dentro do treinamento é o **pré-processamento dos dados de treino**. Que é feito com a *preprocess_covid_data*, que transforma e padroniza os dados no formato adequado para modelagem. Em seguida, é separado as **features** e o **target** do problema. A coluna EVOLUCAO é definida foi *target* y , enquanto todas as outras colunas se tornam *features* X .

No caso do desbalanceamento, é usado a função de balanceamento dos dados *balance_data*, que aplica a técnica de balanceamento oversample. Com isso tem-se o conjunto de dados balanceado ($X_{balanced}$ e $y_{balanced}$), que serão utilizadas no treino.

O modelo usado é o ***HistGradientBoostingClassifier***, um algoritmo de boosting baseado em árvores de decisão, eficiente para grandes datasets e com suporte nativo para tratamento de variáveis categóricas. Ele foi configurado com hiperparâmetros como *max_iter*

= 150, *learning_rate* = 0.1, *max_depth*=10 e *min_samples_leaf* = 20, além de **regularização L2** = 0.1, *early stopping* = *true* e uma fração de validação interna para monitorar a convergência com 0.15 e *n_iter_no_change*=20, *random_state*=*random_state*. Esses parâmetros ajudam a prevenir o *overfitting* e garantem estabilidade no treino.

Foi utilizada ainda ***K-Fold Cross Validation*** nos dados balanceados. A técnica *StratifiedKFold* ajuda na proporção de classes para seja mantida em cada fold, evitando que algum subconjunto fique muito desbalanceado. Para cada *fold*, os dados de treino e validação foram escalonados usando *StandardScaler*, padronizando assim, os valores para média 0 e desvio padrão 1, uma etapa importante, já que para algoritmos de boosting são sensíveis à escala de *features*.

Dentro de cada fold, o modelo foi treinado e suas previsões foram avaliadas usando duas métricas: ***AUC (Area Under the ROC Curve)*** e ***F1-Score***. *AUC* mede a capacidade do modelo em separar corretamente as classes, enquanto o *F1-Score* combina precisão e recall, sendo útil em casos de desbalanceamento. Os resultados de cada fold são armazenados além de fornecerem uma visão do desempenho do modelo antes do treino final.

Após a validação cruzada, o modelo é treinado outra vez usando todos os dados balanceados, com padronização aplicada aos *features* completos (*X_scaled_final*). Então o modelo final treinado, o scaler usado para padronização, os encoders para futuras transformações de dados e a lista das colunas de features.

Em resumo, no treinamento do modelo é feita uma combinação de técnicas de pré-processamento, balanceamento de classes, boosting com árvores de decisão, validação cruzada e padronização de features.

2.5. Predição no conjunto de testes

Para realizar a predição em novos dados de pacientes com *COVID-19*, primeiramente os dados de teste foram submetidos a um **pré-processamento** compatível com o realizado nos dados de treino. Isso envolveu a transformação das variáveis categóricas utilizando codificadores previamente ajustados, garantindo que as representações das categorias fossem consistentes entre treino e teste.

Em seguida, as colunas do *dataset* de teste foram alinhadas com as utilizadas durante o treino. Caso alguma *feature* presente no conjunto de treino estivesse ausente nos dados de teste, ela foi adicionada com valores nulos ou zeros, assegurando que a estrutura dos dados estivesse compatível com o modelo. Após o alinhamento, as *features* selecionadas foram **padronizadas**, aplicando a mesma escala utilizada no treino, para manter a consistência nas magnitudes das variáveis.

Com os dados preparados, o modelo foi utilizado para calcular a **probabilidade de ocorrência do evento de interesse (óbito)** para cada paciente. Estas probabilidades foram então convertidas em **predições binárias**, utilizando um limiar de 0,5, classificando cada paciente em sobrevivência ou óbito. Para análise descritiva, foram registradas estatísticas resumidas das probabilidades, incluindo valores mínimo, máximo, média e a distribuição das classes preditas, permitindo uma interpretação clara do comportamento do modelo sobre os novos dados.

2.6. Execução do pipeline

O pipeline de análise consistiu em três etapas principais: **treino do modelo**, **predição em dados de teste** e **preparação de submissão**. Inicialmente, os dados de treinamento foram utilizados para ajustar um modelo de aprendizado de máquina capaz de prever a evolução clínica de pacientes com *COVID-19*. Durante esta etapa, aplicou-se um **balanceamento de classes**, podendo ser feito por *undersampling*, *oversampling* ou uma abordagem mista, de modo a lidar com o desbalanceamento natural entre sobrevivência e óbito. O modelo treinado foi avaliado por meio de validação cruzada estratificada, garantindo que seu desempenho fosse consistente e robusto.

Com o modelo ajustado, realizou-se a **predição sobre o conjunto de teste**. Os dados de teste foram previamente pré-processados e alinhados com o formato do conjunto de treino, incluindo padronização das variáveis e codificação consistente das categorias. O modelo gerou probabilidades de ocorrência do evento de interesse, que foram convertidas em predições binárias utilizando um limiar de 0,5, classificando os pacientes em sobrevivência ou óbito.

Por fim, os resultados foram organizados em um arquivo de submissão, associando o *ID* de cada paciente à predição correspondente. Além disso, foram calculadas estatísticas

descritivas da previsão, incluindo contagem de casos previstos em cada classe e a taxa de óbito estimada, permitindo uma análise inicial da distribuição das predições geradas pelo modelo.

3. Resultados Obtidos

3.1. Resultados do Pré-processamento e Balanceamento

Após a realização do pré-processamento dos dados de treinamento, chegou-se a um conjunto com **498.320 amostras** e **36 variáveis preditoras**, sem valores nulos. A variável-alvo apresentava um grande desbalanceamento:

Classe	Quantidade	Porcentagem
Alta (0)	326.286	65,5%
Óbito (1)	172.034	34,5%
Razão	0,527	-

Para amenizar esse desbalanceamento, aplicou-se a técnica de **oversampling** na classe de óbitos, igualando o número de instâncias das duas classes:

Classe	Quantidade após balanceamento	Total de amostras
Alta (0)	326.286	652.572
Óbito (1)	326.286	652.572
Razão	1,0	-

3.2. Validação Cruzada com 3 Folds

Com os dados balanceados, foi realizada **Validação Cruzada com 3 folds**, utilizando o modelo **HistGradientBoostingClassifier**. Os resultados médios foram consistentes entre as partições:

Fold	AUC	F1-score
1	0,8072	0,7385
2	0,8067	0,7386
3	0,8079	0,7384

Média ± DP	0,8073 ± 0,0005	0,7385 ± 0,0001
-------------------	-----------------	-----------------

Esses resultados indicam **estabilidade e consistência do modelo** entre as partições da validação.

3.3. Predição no Conjunto de Teste

O conjunto de teste continha **124.581 amostras** com as mesmas 36 variáveis preditoras. Após pré-processamento consistente com o treino, o modelo gerou probabilidades de óbito entre **0,0070 e 0,9924**, com média de **0,4572**. Convertendo em predições binárias (0 = alta, 1 = óbito), a distribuição foi:

Classe prevista	Quantidade	Porcentagem
Alta (0)	67.124	53,9%
Óbito (1)	57.457	46,1%
Taxa de óbito prevista	-	46,12%

Por fim, a submissão final foi gerada em formato binário, associando cada paciente a uma predição de evolução clínica (0 para alta e 1 para óbito), totalizando **124.581 predições**, compatíveis com o esperado para avaliação externa do modelo. Esses resultados demonstram que o modelo foi capaz de lidar com o desbalanceamento e apresentar predições consistentes tanto em treino quanto em teste.

Observações:

- O **balanceamento das classes** foi crucial para reduzir o viés do modelo e melhorar a capacidade de previsão da classe minoritária.
- A **validação cruzada** demonstrou consistência nas métricas AUC e F1-score.
- As **predições no teste** mostram que o modelo foi capaz de identificar adequadamente os casos de alta e óbito, com distribuição relativamente equilibrada.

A imagem a seguir tem os resultados de treinamento e teste do modelo, as métricas AUC e F1-Score:

```
➡ Preprocessando dados de treino...
Shape: (498320, 37), Nulos: 0
Features: 36, Amostras: 498320
Distribuição target original: {0.0: 326286, 1.0: 172034}
Antes do balanceamento:
  Classe 0 (alta): 326286
  Classe 1 (óbito): 172034
  Ratio: 0.527
Após balanceamento (oversample):
  Classe 0 (alta): 326286
  Classe 1 (óbito): 326286
  Total de amostras: 652572
  Novo ratio: 1.000
\nIniciando 3-Fold Cross Validation nos dados balanceados...
Fold 1/3
  AUC: 0.8072, F1: 0.7385
Fold 2/3
  AUC: 0.8067, F1: 0.7386
Fold 3/3
  AUC: 0.8079, F1: 0.7384
Treinando modelo final...
\nCV Results - AUC: 0.8073±0.0005
CV Results - F1: 0.7385±0.0001
Preprocessando dados de teste...
Shape: (124581, 36), Nulos: 0
Fazendo previsões...
Probabilidades - Min: 0.0070, Max: 0.9924
Probabilidades - Média: 0.4572
Previsões binárias:
  - Altas (0): 67124 (53.9%)
  - Óbitos (1): 57457 (46.1%)
Submissão com previsões binárias salva!
Total de previsões: 124581
Altas previstas (0): 67124
Óbitos previstos (1): 57457
Taxa de óbito prevista: 46.12%
```

4. Discussão sobre o Comportamento dos Métodos

A análise dos resultados obtidos pelo modelo HistGradientBoostingClassifier indica que o pipeline desenvolvido foi capaz de entender padrões relevantes para a predição do risco de morte em pacientes com SRAG, apresentando desempenho consistente nas métricas avaliadas. A validação cruzada mostrou valores de AUC e F1-score compatíveis com modelos preditivos confiáveis, demonstrando a capacidade do modelo em diferenciar pacientes que evoluíram para óbito daqueles que tiveram alta hospitalar.

O uso de *engenharia de features* revelou-se fundamental para melhorar a discriminabilidade do modelo. Variáveis derivadas, como *total_comorbidades*, *risco_idade_comorb* e *saturacao_baixa*, contribuíram significativamente para a identificação de pacientes de alto risco. Esses fatores clínicos são compatíveis com evidências médicas conhecidas, reforçando a validade do modelo sob a perspectiva epidemiológica.

O balanceamento das classes também se mostrou crucial, uma vez que a classe de óbitos representava uma minoria significativa no conjunto de dados. Estratégias como oversampling, undersampling e abordagem mista permitiram que o modelo aprendesse adequadamente os padrões da classe minoritária, evitando vieses que poderiam reduzir a sensibilidade para casos críticos. Observou-se que a abordagem mista apresentou melhor equilíbrio entre precisão e sensibilidade, refletido em métricas mais estáveis durante a validação cruzada.

Apesar dos bons resultados, algumas limitações foram identificadas:

1. Dependência de dados completos e consistentes: registros incompletos ou com informações inconsistentes podem impactar negativamente o desempenho do modelo, mesmo com técnicas de imputação.
2. Generalização para diferentes populações: o modelo foi treinado com dados brasileiros, o que pode limitar sua aplicabilidade a outros contextos geográficos ou demográficos.

Além disso, a interpretação dos resultados deve ser realizada com cautela, considerando que o modelo não substitui o julgamento médico. Ele funciona como uma ferramenta de apoio à decisão, capaz de priorizar casos de alto risco e ajudar na alocação de recursos hospitalares.

Os resultados obtidos reforçam a relevância do *HistGradientBoostingClassifier* para problemas de classificação em saúde, especialmente quando há grande número de variáveis e desbalanceamento de classes. A análise das probabilidades geradas pelo modelo também permite identificar pacientes com risco elevado, oferecendo insights úteis para intervenções precoces e planejamento hospitalar.

5. Conclusão

Este trabalho possibilitou aplicar o que foi visto em sala de aula, neste caso aplicando de técnicas de *Machine Learning* para a predição do risco de morte em pacientes com Síndrome Respiratória Aguda Grave (SRAG), utilizando o modelo *HistGradientBoostingClassifier*. O pipeline desenvolvido inclui pré-processamento, engenharia de features, balanceamento de classes e validação cruzada, alcançando desempenho consistente, com **AUC média de 0,8073** e **F1-score de 0,7385**.

As variáveis derivadas como *total_comorbidades*, *total_sintomas*, *risco_idade_comorb* e *saturacao_baixa* mostraram-se relevantes para obter padrões clínicos importantes, alinhados com evidências médicas. O uso de *oversampling* foi fundamental para lidar com o desbalanceamento e melhorar a detecção de casos críticos.

Embora apresente bons resultados, o modelo possui limitações, como a dependência de dados completos e a restrição ao contexto brasileiro. Futuras melhorias podem incluir a exploração de outras técnicas de balanceamento (como SMOTE), ajustes de thresholds para otimizar a sensibilidade e o uso de modelos mais interpretáveis para apoiar a prática clínica.

Em resumo, os resultados obtidos evidenciam o potencial da inteligência artificial como ferramenta de apoio à decisão médica e à gestão hospitalar, permitindo identificar pacientes de maior risco de forma mais rápida e fundamentada.